

Keeletehnoloog teoretiseerib korpuse üle

Heiki-Jaan Kaalep
Tartu Ülikool

Kava

1. Sissejuhatus: keel ja korpus
2. Isiklik ajalugu
 1. Programmeerija ... testija ... (korpus)lingvist
(Keele)tehnoloogia on teooria rakendamine ja kontroll Kas ikka on?
Probleemid keele kirjeldustes → vigane programm
 2. Korpus kui näidete või reeglite allikas
 1. NB! Reeglid olgu üldised, s.t. korpusest sõltumatud
 2. Alati ei õnnestu reegleid koostada → korpusepõhised loendid...
3. Andmete valimise kunst
4. Millist korpust saab usaldada ja mille osas?

2.1 Isiklik ajalugu – kuidas ma alustasin keelekauge inimesena ja kuidas ning miks olen nüüd muutunud lingvistiks (igatahes ennast ma selleks pean)

Eesmärk oli teha õigekirja kontrollija e speller – teiste keelte jaoks oli olemas, seega...

2.2. kuidas programmeerijana või arendajana kasutasin korpust

3 kuidas minu arvates võiks korpustele (nende statistikale) vaadata

4. Aga kui korpus tundub vale? Või tundub õige, aga kas saan oma tunnet usaldada?

Sissejuhatus: keel ja korpus

Korpus = andmed

Keel = reeglid e. algoritm

Keele kasutamine annab korpuse = Reeglite rakendamine annab andmed

Paradoks: reeglid pole (lingvistile) teada

Räägime, aga lingvistid ei tea, kuidas laps selle õppis

(Kui teaks, siis võiks ka arvuti rääkida/kirjutada)

Lingvisti ülesanne: leia reeglid andmete kaudu

... nad on seda alati proovinud teha...

On reeglid üldse leitavad?

See on suht triviaalne, aga lihtsalt igaks juhuks räägin ära, et oleksime n-ö samal lainel

Hume, Chomsky: hane näide (mida kordavad McEnery ja Brezina “Fundamental Principles of Corpus Linguistics” 2022)

Morfoloogia teooria = algoritm

1. Mida on üldse vaja moodustada?
 1. Millised sõnavormid on olemas ja mida nad grammatiliselt tähendavad?
 2. Paradigmatabeli kuju
2. Millistest osadest (morfeemidest) kokku pannakse (morfotaktika)?
 - morfeemi sisu (gr. kat.) ja vorm (morf)
 - nt mitmus – de/te/e/u/i
 - minevik – nu/s/is/i
3. Milliste reeglitega kokku pannakse?
 - M.h. mis on algvorm?
4. Milliste reeglitega morfe muudetakse (morfofonoloogia)
 - astmevaheldus, vokaalide madaldumine, ...

Programm peaks kasutama teooriat

Teooria = algoritm e. eeskiri kuidas sõnavorme moodustatakse

Need 4 punkti on algoritmi olulised osad

Näited lingvistide algoritmilisest argumentatsioonist

“Tugevast astmest nõrka moodustada on kergem” (Ahrens, Wiedemann)

“...peab näitama, missugusest tüvevariandist missugune vorm moodustatakse” (Peebo)

“Ei ole võimalik ühegi algvormi puhul esitada sünteesireegleid, mille abil saaks teisi tüvevariante genereerida” (Ehala)

Lihtsalt et te usuksite, et teooria küsimused on algoritmi küsimused, moodustamiseeskirja küsimused

Algoritmi kirjeldusest programmiks e. vabamorfi tegemise etapid

1. Lihtsõnade analüüs – VVS
Sõnavara katvus, morfoloogiline kirjeldus OK
2. Tuletised, liitsõnad
Reeglid kirjeldatud jutuna (R. Kasik, R. Kull) + vt ka korpusi
(näiteid; kriteerium arendamise lõpetamiseks – kui
tundmatuid liitsõnu oli sama palju kui kirjavigu)
3. Oletamine (minu jaoks uus mõte)
 1. Ideed (Ü. Viks, K. Ross) + vt korpusi statistiliselt
 2. Sõnasagedusstatistika (hapax)

Kuidas olemasolnud teooria programmiks sai – millised olid etapid ja millised olid nende n-ö väljatöötatuse astmed programmi loomise ajal

1 võttis 4 kuud, 2 võttis poolteist aastat – kokku u. 2 aastat (küll ma olin noorena kiire...) 1993 oli valmis?

3 Ideed teistel juba 1980ndatel, minuni 1990ndatel, kusjuures algul ma ei pidanud oluliseks (ei võtnud Ü. Viksi tõsiselt, kes sellest silmade põledes rääkis; nüüd räägin ise silmade põledes); tegin oletaja ja ühestaja u. 2000

Vajadus tekkis sellest, et hakati korpusi töötlemata ja sõnastikus teatavasti ei ole kunagi kõiki sõnu

Algul proovisin sõnastikku muudkui täiendada, aga pärast oletaja valmimist pole see enam huvitav

Hiljem olen programmi korduvalt ümber kirjutanud. Esiteks sain ise targemaks ja esialgsed algoritmid osutusid valedeks, NB! **loetamatuteks** !!! (kajastasid kirjutamise aegset arusaamist); teiseks arenesid arvutiplatvormid (üleminek linuxile, C++), kolmandaks olen aeg-ajalt lisanud suuri sõnahulki leksikoni (thesaurus 1997, sagedussõnastik 2002)

Vabamorf kui teooria ?

Sõnastikupõhine analüüs/süntees on ka teooria?

Halb (?) eeskuju ÕS-idest

Kas paralleelvormid on või pole?

*seppadel/*sepil, Pariisi/*Pariisisse*

“Teoreetiliselt võimalikud” sõnavormid

*muuseum+e/eid/*isid*

Võimalikud ja tegelikud sõnad

hila, ask, tära (ÕSis kuni 2006)

→ tavaline leksikograafi töö (sõnastiku korrastamine)

üksiksõnade eemald/lisam

muuttüüpide modif. (**sepil*)

Või oleks õigem öelda, et Vabamorf kui praktiline leksikograafi töö???

See slaid käib ikka veel kavas punkti 2.1 alla...

ÕS pakub liiga palju paralleelvorme

Vabamorfi jaoks tehtud otsused olid lihtsalt korpusega kooskõlas, mitte teoreetiliselt põhjendatud

“kas mulle tundub see sõnavorm loomulik?” v.s. “aga Õsis on nii”

Õige programm, valed tulemused

“Katseklaasis ujub sirbikujulisi värde”

(VVS, ÕS: *värd, värra, värda* mitm. os. *värdi* e. *värdasid*)

→ avastasin uue muuttüübi?

käppe, jalge, ... ?

Ei... *värd, värdi, värdi*, mitm. os. *värde*

(*äpp, laik, ...*)

Kontrollides oma programmi tööd Horisoni tekstikorpusel, leidsin, et programm ei tunne ära tekstis olevat sõnavormi, kuigi sõna “värd” oli leksikonis olemas... Osutus, et muuttüüp oli vale

Programmi kohandamine tähendab teooria muutmist vist??? Või on see ka lihtsalt leksikograafi töö?

Vabamorf kui teooria: oletaja kui keeletunde imiteerija

Mistahes sõna puhul me teame, kuidas selle vorme moodustada; ka tundmatu sõna puhul

Oletamine: milline võib olla sõnavormi algvorm?

<i>pee</i> le = <i>pe</i> <i>el</i> ains. om.	← keel
<i>pe</i> el mitm. os.	← steel
<i>pee</i> le ains. nim/om	← Adeele

Vahemärkus: tavaliselt me räägime, et probleemiks on, kuidas sõnavorme moodustada; aga korpuste analüüsil on probleemiks, kuidas analüüsida juba moodustatud. Tegelt see on sümmeetriline probleem: pakkuda välja algvorm mis võiks olla tekstis oleva sõnavormi algvorm e. sõnastiku märksõna e. lemma pluss milline võiks olla tekstis oleva sõnavormi grammatiline tähendus (arv, kääne)

Keel - keele ei saa olla uue sõna muutumismalliks, selleks saab olla steel steeli steeli, m. os. steele

Keeletaju

Käänamis- ja pööramisviisi peab määrama sõna väline kuju (sest muule pole tugineda)

- haruldase ja väljamõeldud sõna muutmine on ühesugused
- see käänamine tundub loomulik, tavapärane (teistsugune oleks naljakas, nt *äpp:äpu*, *äpp:äpa*)
- kui ühesug. kujuga sõnadel on erinev muutmisviis, siis produktiivne on see viis, mis juba kehtib suuremale hulgale sõnadele

NB! “sõna” all mõtlen siin sõnavara üksust, mitte teksti üksust, s.t. suurem hulk sõnu = suurem leksikon -- nagu edaspidi näitan

Andmete valimise kunst

Kuidas saavutada, et Vabamorfi oletaja imiteeriks keeletunnet e.
pakuks just produktiivseid malle?

Mina oma keeletunnet lõpuni ei usalda

Kas keele kirjeldusi võib usaldada?

Vaata korpuse **sõnavara** !

Kunst on siin liiga suurejooneline sõna

Küsimus on siin muidugi selles, et kuidas programmeerija teab, milliseid malle ta peab Vabamorfile programmeerima?

Keelekirjelduste usaldamise puhul teeb veidi ettevaatlikuks kogemus Õsiga ja teadmine, et korpuslingvistika on siiski uuemat sorti asi Eestis... vist

Et tuleb vaadata sõnavara, pole muidugi mingi uudis, aga mulle tundub, et korpusest sõna (sagedus) loendite tegemine ei ole Eesti korpuslingvistide hulgas levinud tava – vast diskussioonis mind parandatakse, kui eksisin.

Keeletaju (1 silp, lõpus kaash.)
näpp, rüpp, käpp, täpp

Varem nähtud türevokaal


Tundmatu sõna türevokaal

Tekstis

+u 15%
+e 5%
+a 30%
+i 50%

Sõnavaras

+u 9%
+e 1%
+a 5%
+i 85%



+u 0%
+e 0%
+a 0%
+i 100%

Pülk näide

Keeletaju (2 silpi, II välde, lõpus s)

kinnas, pinnas, soodus, boonus

Varem nähtud mall

Tekstis

on a-v 50%

pole a-v 50%

Sõnavaras

on a-v 34%

pole a-v 66%

Tundmatu sõna mall

on a-v 0%

pole a-v 100%



Vahekokkuvõte

Vaata sõnavara, võrdle loendeid, ignoreeri sõna kordumisi
tekstis !

See on siin vahepeal lihtsalt meeldetuletuseks, et korpuse vaatamise viis on tähtis, seda hoiakut läheb edaspidi vaja

Vabamorfi kood: inseneri või teadlase vaade

Loendid (lõpud, liited, tüved, erandid, ...) +
kombineerimisreeglid

Näited

1. Loend, mis kajastab reeglit

Produkt. muutmismallide loend oletamiseks:

jakk, paak, punk, ...

2. Loend, mis kajastab lihtsalt korpust

Ei sobi oletamisel liitsõna viimaseks komponendiks:

biit, bool, boor, emis, enne, foon, ...

Oletused: *valgus_foon, blama_meister, blamafoon,*
**blama_foon*

Nüüd tulen tagasi selle juurde, et pahatihti ma ei tea, mida peaks vaatama (erinevalt just eelnevast kiitlemisest, kuidas ma tean, kuidas teatud liiki keeletaju kujuneb)

Vabamorfis on ka selliseid loendeid, mis lihtsalt hoiavad ära mõnede suuremate lolluste tegemise.

Nt. St. ei lubata oletada, et liitsõnal võib olla viimaseks komponendiks foon, kui esimene komponent pole teadaolev eestikeelne sõna – reegel iseenesest on üsna mõistlik, aga teoreetilise aluseta

Ma rohkem ei häid ega inetuid loendeid ei näita, vast usute niigi

Inseneri seisukohalt on vabamorf päris hea, töötab küll. Teadlase jaoks on temas aga põhjendamatuid osi. Ja kui kindel saab olla, et tema headus pole osav pettus, nt teda pole kohandatud ajalehetekstidele, mida ongi korpustest kõige rohkem ja mis jätavad temast hea mulje ?

Mida korpus esindab?

Korpus = hulk tekste

valdkond + keelekasutus

Korpus <--> “**üldkogum**”, “üleüldine keelekasutus”

sarnane / esinduslik / representatiivne

mudel <--> originaal

Ülesanne: leia parameetrid, mis korpuses ja “üldkogumis” on ühesugused

Näide: gloobus <--> Maa : vahekaugus

Tartu – Kiiev, Tartu – Istanbul

absoluutsuurus erineb, aga suhe sama

Analoogia: gloobus on Maa mudel ühes kindlas mõttes – maapealsete vahekauguste suhte mõttes; pluss kuju - kera - poolest (sest muidu vahekauguste suhted ei saaks olla adekvaatsed)

Arvutades gloobuse põhjal võime tulemuse üle kanda Maa peale

Ühtegi muud maa omadust gloobus ei kajasta

Gloobus on nii tehtud, et Maapealsed mõõtmised kajastuksid seal õigesti (leivapätsi kujulisel ei kajastuks)

Oleks hea, kui korpuse peal leitud seaduspärasused kehtiksid ka üldkogumil

“Üleüldine keelekasutus” on väga raske määratleda, “sarnasus on ka väga raske määratleda

Kas korpus esindab

- keelekasutust, mis on keele (all)süsteemi kujunemise/muutumisega kooskõlas?
→ sel juhul on ta üldkogumiga sarnane
- kõigest keelekasutuse näiteid?
→ ikka kasulik, aga ...

Keel vs kasutus (sissejuhatuses – suund oli keelelt kasutusele, s.t süsteem loob korpuse)

Nüüd: korpus loob süsteemi ??? Põhim. ju teame, et nii see peabki olema – lapsed ju nii õpivad, aga ...

“süsteem” võib olla sõnamuutmine, tähenduste süsteem, mis iganes ?

Analoogia gloobusega lõppeb, sest korpust ei “tehta”, vaid valitakse

Kas valisime ümmarguse või pätsikujulise keha? (oletame, et keelekasutus on “ümmargune”)

Tegelt: “mis kujuline on keelekasutus”? S.t. milline (arvuline) parameeter seda iseloomustab?

Parameetri jahil

Kooskõla

inimese (1) võimete,
keeleelemendi keerukuse (**≈pikkuse**) (2)
ja **sageduse** (3) vahel

(1) omandatakse (laste poolt)	varem	hiljem
(2) kuju	lühem	pikem
(3) kordub tekstis	rohkem	vähem

Otsin seoseid keelest ja korpusest väljaspool, et millelegi välisele toetuda

Sõnamuutus: süsteemi ja korpuse kooskõla

- Sõna muutevormid on erineva kasutussagedusega
 - Sagedam vorm tuleb varem ette kui harvem
 - Üldiselt: paradigma liikmed on erineva kasutussagedusega
nim > om; ains > mitmus
 - Sagedam liige tuleb varem ette kui harvem liige
 - Ainult varem teadaolevast saab moodustada uue vormi
- ⇒ muuteparadigmadel on vormide hierarhia (Bybee)
... mis on üldkogumiga kooskõlas

Konkreetne keele alamsüsteem...

Üldised keele seaduspärasused (Bybee); seovad loogiliselt keelekasutuse statistika ja sõnavormide moodustamise algoritmi põhimõtte, s.t. võimalike sammude ja reeglite süsteemi

Käändsõna paradigma

	ainsus	mitmus
nimetav	redel	redelid →
omastav	redeli	redelite →
osastav	redelit	redeleid
sisseütlev	redelisse	redelitesse
seesütlev	redelis	redelites
...	...	...
ilmaütlev	redelita	redeliteta


Käänevormid:

Kasutussagedus väheneb paremalt vasakule ja ülevalt alla (Greenberg)

Pikkus suureneb --- „ ---

Omandamisjärjekord: algab a. nim-st

Käändsõna paradigmaliikme tavalisus



Morf ühestatud korpus cl.ut.ee lehelt

NB! Vt sõnavara, mitte lihtsalt sõnavorme, sest

1. Püüan vältida olukorda: “samal ajal” on sage, aga see ei tähenda, et alalütlev kääne on sage, s.t tahan sama sõnavormi kordused arvutustes välistada
2. Peaks olema nii, et sõnavormi aluseks olevat vormi on varem kohatud, s.t. kui korpus on “redelit”, siis on seal ka “redel” ja “redeli”. Korpus on aga ligikaudne mudel, s.t mitte iga sõna puhul ei pea kehtima, et leidub ka alusvorm, aga keskmisena peaks ikka olema nii, et alusvormina esinevate sõnade loend on mitte lühem kui neist tuletatavate vormide loend.

Korpus on kooskõlas vormide omandamise järjekorraga ja pikkustega ning nad on ühesugused, v.a. seadused (mis on ka intuiitiivselt mitte-loomulik keel)


Tegusõna paradigma: analoogiarühmad

∅	hüppa, -n, -d, -b, ... -ksin, -ks	nuta, -n, -d, -b, ... -ksin, -ks
GE	hüpa-ke, -kem, -ku	nut-ke, -kem, -ku
MA	hüppa-ma, -mas, ... -va	nut-ma, -mas, ... -vat
S	hüppa-sin, -sid, ...	nut-sin, -sid, ...
NUD	hüpa-nud, -nuksin, -nuks, ... -nuvat	nut-nud, -nuksin, -nuks, ... -nuvat
DA	hüpa-ta, -tes	nut-ta, -es
TUD	hüpa-tud, -ti, -takse, ...	nute-tud, -ti, -takse, ...

Kaks näitesõna

Oletus, millised võiksid olla põhivormide vahelised sõltuvused; kõige aluseks on lõputa vorm

Tegusõna paradigmaliikme tavalisus



Morf ühest korpus cl.ut.ee lehelt; chilles on mujalt

Siin vaatan verbi paradigma liikmeid, mis võiksid olla teiste vormide moodustamise aluseks.

Suur erinevus käandsõnadest – sagedusjärjestused on erinevad ja mis kõige olulisem: mitmel juhul pole kooskõlas omandamisjärjekorraga laste poolt ning lühidusega

Kõige suurema levimusega paradigmaliige on eri korpustes erinev

Verbi formatiivid korpustes: kokkuvõte

- Eri korpused, eri sagedusjärjestused
 - Sagedus ei ole alati kooskõlas formatiivi lühidusega
 - Erinevus ei tulene “suulisusest”
 - Lõputa vorm sagedaim **hoidjakeeles** ja **jututubades**
=> **õiges korpuses** ei ole lood, narratiivid, vaid koos tegutsemisega seotud jutt?
vrd majaehitus (*anna haamer, võta ise, nii ei saa, ära siia astu*)
- Lõputa vorm: (1) omandatakse kõige varem, (2) on lühim, (3) on **õiges korpuses** sagedaim

Leidsime morfoloogiasüsteemi põhimõtetega kooskõlas (ja mitte kooskõlas) olevad korpused.

(See on teada väljaspool neid korpusi, et lõputa vorm on see verbi vorm, mille lapsed esimesena omandavad)

Korpus, mille parameetrid pole morf. süsteemi põhimõtetega kooskõlas, ei saa olla keelekasutuse kui üldkogumi esindajaks e. mudeliks.

Korpuse sobivus

Paljud korpused ei sobigi sõnamuutmissüsteemi uurimiseks !?!

Kui sõnamuutmissüsteem kujuneks nende järgi, siis oleks ta teistsugune kui see, mida me näeme ta olevat.

... Aga mõne teise aspekti uurimiseks ?

Muutuse sammud “vales” korpuses EtTenTen
naase tõuse → *ela*
veena, mööna *naera* → *pööra*

Ø	DA	S	MA	NUD	TUD	GE
naase	naasta	naasis	naasma	naasnud	naastud	naaske
200	naaseda	naases	naasema	naasenud	naasetud	naasege
	2000/100	1200/500	400/40	1500/20	200/0	10/0
veena	veenda	veenis	veenma	veennud	veendud	veenge
500	veenata	veenas	veenama	veenanud	veenatud	veenake
	3500/1	500/20	500/1	300/1	100/0	20/0
mööna	möönda	möönis	möönma	möönnud	mööndud	möönge
20	möönata	möönas	möönama	möönanud	möönatud	möönake
	300/0	1800/40	400/1	100/1	10/0	1/0

Vastan eelmise slaidi küsimusele praktilise näitega, kuidas vales korpus tegutseda.

Jätkan oma lemmiku morfoloogiga, nüüd teadvalt vales korpuses. Aga kuna ma nüüd tean, mis mõttes see korpus kajastab sagedusi valesti (s.t. teisiti kui “üldkeel”), siis vaatan ainult neid sagedusi, mis ei puuduta paradigma ülesehitust.

Ø, S ja MA sagedusvahekorrad on (arvatavasti) eksitavad; aga vana/uue vormi vahekorrad vast mitte, s.t. saame hinnata analoogiagrupi ülemineku kiirust uuele muuttüübile.

Uurimisküsimus: kas MA on S aluseks või S on MA aluseks?

Põhjendus: alusvorm peaks muutuma enne kui teda järgiv vorm → see, mis on kaugemale arenenud, ongi alusvorm

Näeme, et S liigub kõige kiiremini uue muutmispalli poole ja et naase on jõudnud kaugemale kui veena ja mööna.

Muide, pööra oli kunagi ise naera tüübis – pööрма, pööris, pöördud jms.

Mõte: korpus ja tiraaž

Korpus esindab keelesüsteemi toimimise tagajärge, tiraaži korpuse tegemisel ei arvestata

Aga kui korpus on keele süsteemi kujunemise aluseks, siis tiraaž on oluline

Idee on selles, et iga kõneleja on võrdne; kui ühe juttu tiražeeritakse rohkem, siis see muudab keelesüsteemide esindajate tasakaalu.

(Samal põhjusel võib palju publitseerivaid autoreid ka osaliselt ignoreerida).

Kui korpuse põhjal tekib süsteem, siis tiraaž on kindlasti oluline. Aavik soovides oma uudissõnu levitada avaldas neid paljuloetavates e. tiražeeritavates žanrites - põnevus- ja õudusjuttudes.

Pülga autorid oleksid pidanud kirjutama põnevusjutu mälupulga kadumisest

Võib-olla nt. uute sõnade leviku uurimisel oleks just õige tiraaži arvestada ?

Lõpetuseks

Alustasin lihtsameelse programmeerijana, nüüdseks olen vist lingvistiks muutunud ja tunnen muret, et kust keeleuurija adekvaatseid andmeid saaks.

Alguses uskusin, mida keeleraamatud kirjutasid, nüüd ei usu alati enam korpustki.

Pean ütlema, et lingvist olla on huvitavam kui programmeerija.